Ferramentas de Softwares para uso em ciência de Dados II

OBJETIVO

Nasser Santiago Boan

> arquivologia - UNB

> tecnologia do Petróleo e Gás - UFRJ

> MBA Processos de Negócio - IBMEC

> IBM Data Science Professional Certified

> líder de Ciência de Dados - Certsys

> Cientista de Dados - Stefanini

> docente Pós-Graduação Ciência de Dados

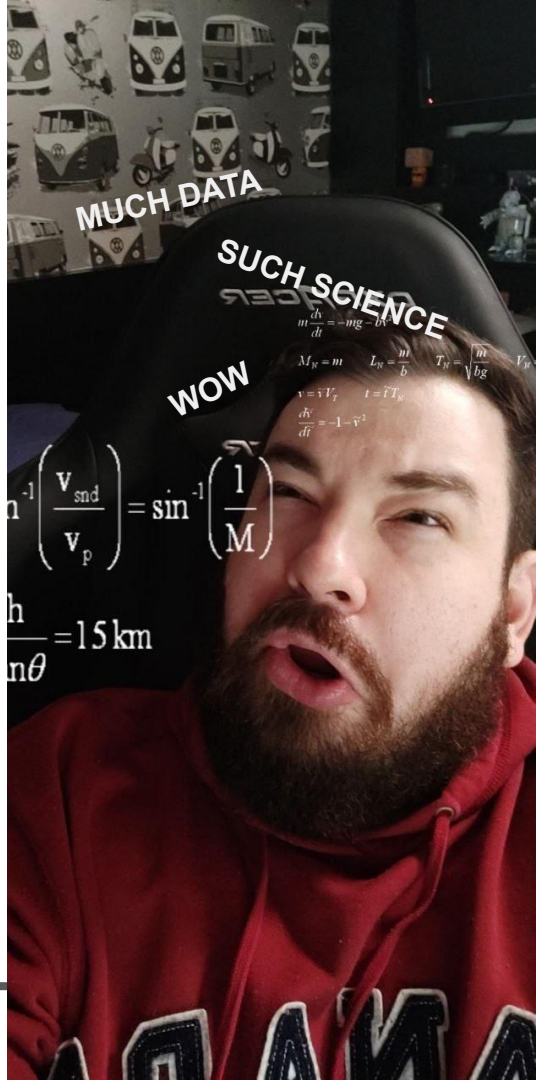

Ementa

- Básico
  - pip
  - conda
  - miniconda
  - jupyter notebook
- Nivelamento 2
  - Variáveis e operações matemáticas
  - Operações com strings
  - Listas
  - Tuplas
  - Dicionários
  - Condições lógicas
  - Loops (for + compreensão de lista + while)
  - Funções (def + lambda)
  - Funções built-in (zip, enumerate,map e filter)

Ementa

- Files
  - Lendo arquivos com OPEN
  - Escrevendo arquivos com OPEN
- Numpy
  - Numpy array
  - Operações com arrays
  - Indexing e slicing
  - Stacking
  - Funções estatísticas (mean, var, std, median, quantiles)

IESB

Ementa

- Pandas
  - Dataframes
  - read_ / to_
  - Indexing e slicing (.loc , .iloc , filter , head, sample)
  - Tipos de dados e datas (to_datetime)
  - Funções estatísticas (describe, corr, skew, mode, unique, nunique)
  - Transformações (apply + operações com séries)
  - Reshaping e sorting (pivot + transpose + nlargest + nsmallest + value_counts + sort_values)
  - Concat e merge
  - Valores nulos (isna, isnull, fillna-- imputação --, drop, dropna, replace)
  - Method Chaining

IESB

Ementa

- matplotlib
  - Arquitetura (pyplot e axes)
  - Anatomia dos gráficos em matplotlib
  - Plotando (figure, plt.bar, plt.scatter, plt.plot, title, labels, legend, colors, axvline, axhline)
  - Subplots
  - Abrindo imagens
  - Exportando gráficos (plt.savefig)

IESB

Ementa

- Scikit-Learn
  - Pre-processamento (standartscaler, minmaxscaler, onehotencoding)
  - Conceitos de Regressão / Classificação / Clusterização
    - Dataset de treino e teste (train_test_split)
    - Underfitting / overfitting
  - Regressão linear simples (na mão + coeficientes explícitos)
    - Métricas de regressão e função de custo
  - Regressão linear múltipla e polynomial features
  - DecisionTree / RandomForest
    - Métricas de classificação
  - KMeans
    - métricas de clusterização
  - Kfold e GridsearchCV

Avaliação

- Lista 01 (python)
- Lista 02 (pandas + matplotlib)
- Projeto 01 (análise de dados)
- Lista 03 (conceitos de machine learning 1)
- Lista 04 (conceitos de machine learning 2)
- Projeto 02 (projeto ML)

IESB

Módulo Básico

pip

O pip é o gerenciador de pacotes do python.

```
$ pip install <nome do pacote>

$ pip --version

$ pip list

$ pip install -r requirements.txt
```

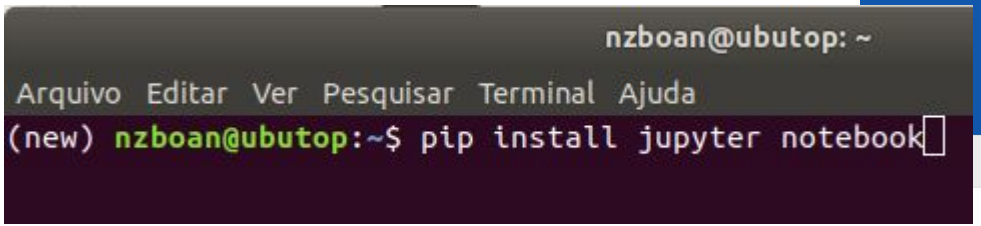

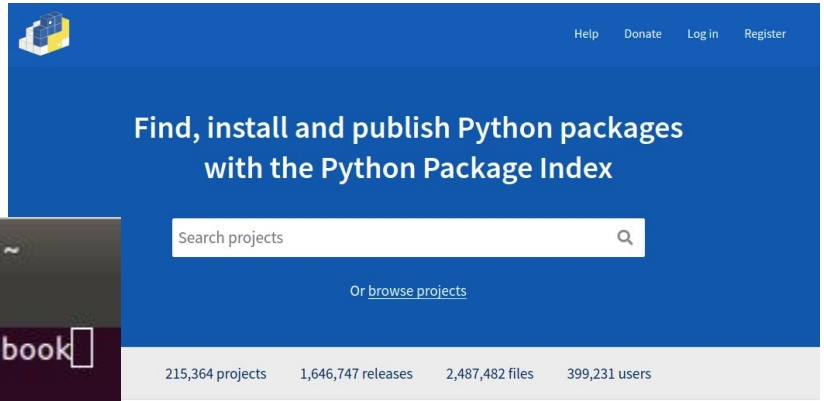

conda e miniconda

O conda vai além e gerência ambientes e dependências

```
$ conda create env -n <nome do ambiente>

$ conda create env -n <nome do ambiente> python=3.6

$ conda env create -f environment.yml

$ conda list

$ conda install <nome do pacote>

$ conda activate <nome do ambiente>

$ conda deactivate <nome do ambiente>
```

IESB

conda e miniconda

O conda vai além e gerência ambientes e dependências

```
(base) nzboan@ubutop:~$ conda list
# packages in environment at /home/nzboan/miniconda3:
#
# Name                    Version                   Build  Channel
_libgcc_mutex             0.1                         main
_tflow_select             2.1.0                       gpu
absl-py                   0.8.1                    py37_0
altair                    3.2.0                    py37_0
asn1crypto                1.2.0                    py37_0
astor                     0.8.0                    py37_0
astroid                   2.3.3                    py37_0
attrs                     19.3.0                     py_0
backcall                  0.1.0                    py37_0
beautifulsoup4            4.8.1                    py37_0
biopython                 1.74                     pypi_0    pypi
blas                      1.0                         mkl
bleach                    3.1.0                    py37_0
blosc                     1.16.3               hd408876_0
bokeh                     1.4.0                    py37_0
boto3                     1.9.232                  pypi_0    pypi
botocore                  1.12.232                 pypi_0    pypi
branca                    0.3.1                      py_0    conda-forge
bzip2                     1.0.8                h7b6447c_0
c-ares                    1.15.0               h7b6447c_1001
ca-certificates           2019.11.27                  0
cachetools                3.1.1                    pypi_0    pypi
cairo                     1.14.12              h8948797_3
certifi                   2019.11.28               py37_0
cffi                      1.13.2           py37h2e261b9_0
chardet                   3.0.4                 py37_1003
click                     7.0                      py37_0
click-plugins             1.1.1                    pypi_0    pypi
cligj                     0.5.0                    pypi_0    pypi
cloudpickle               1.2.2                      py_0
cogroo-interface          0.3                      pypi_0    pypi
colorcet                  2.0.2                      py_0
conda                     4.8.1                    py37_0
```

IESB

conda e miniconda

O conda vai além e gerência ambientes e dependências

```
(base) nzboan@ubutop:~$ conda activate new
(new) nzboan@ubutop:~$ conda list
# packages in environment at /home/nzboan/miniconda3/envs/new:
#
# Name                    Version                   Build  Channel
(new) nzboan@ubutop:~$
```

```
In [5]: from sklearn.datasets import load_iris

---------------------------------------------------------------------------
ModuleNotFoundError                       Traceback (most recent call last)
<ipython-input-5-56d11ecab3a7> in <module>
----> 1 from sklearn.datasets import load_iris

ModuleNotFoundError: No module named 'sklearn'
```


IESB

conda e miniconda

```
(new) nzboan@ubutop:~$ conda install scikit-learn
Collecting package metadata (current_repodata.json): done
Solving environment: done

## Package Plan ##

  environment location: /home/nzboan/miniconda3/envs/new

  added / updated specs:
    - scikit-learn


The following packages will be downloaded:

    package                    |            build
    ---------------------------|-----------------
    ca-certificates-2020.1.1   |                0         125 KB
    certifi-2019.11.28         |           py38_0         153 KB
    ld_impl_linux-64-2.33.1    |       h53a641e_7         568 KB
    mkl-service-2.3.0          |   py38he904b0f_0          62 KB
    mkl_fft-1.0.15             |   py38ha843d7b_0         159 KB
    mkl_random-1.1.0           |   py38h962f231_0         340 KB
    numpy-1.18.1               |   py38h4f9e942_0           5 KB
    numpy-base-1.18.1          |   py38hde5b4d6_1         4.2 MB
    openssl-1.1.1d             |       h7b6447c_3         2.5 MB
    pip-20.0.2                 |           py38_1         1.7 MB
    python-3.8.1               |       h0371630_1        49.5 MB
    scikit-learn-0.22.1        |   py38hd81dba3_0         5.4 MB
    scipy-1.3.2                |   py38h7c811a0_0        14.0 MB
    setuptools-45.1.0          |           py38_0         522 KB
    six-1.14.0                 |           py38_0          27 KB
    sqlite-3.30.1              |       h7b6447c_0         1.1 MB
    wheel-0.34.1               |           py38_0          50 KB
    ------------------------------------------------------------
                                           Total:        80.3 MB
```

```
In [2]: from sklearn.datasets import load_iris

In [9]: data = load_iris()

In [10]: data.target

Out[10]: array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2])
```


IESB

conda e miniconda

environment.yml

```yaml
name: stats
dependencies:
  - jupyterlab
  - pandas
  - numpy
  - scikit-learn
```

```
(base) nzboan@ubutop:~$ conda env create -f environment.yml
```

```
(base) nzboan@ubutop:~$ conda env create -f environment.yml
Collecting package metadata (repodata.json): done
Solving environment: done

Downloading and Extracting Packages
pandas-1.0.0         | 8.8 MB    | ##################################### | 100%
jupyterlab-1.2.5     | 2.8 MB    | ##################################### | 100%
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
#
# To activate this environment, use
#
#     $ conda activate stats
#
# To deactivate an active environment, use
#
#     $ conda deactivate

(base) nzboan@ubutop:~$
```


IESB

jupyter notebook

O jupyter notebook é documento que contém tanto código quanto elementos de texto. Ele executa código célula a célula, pode ser lido por humanos (human-readable) ou pela máquina (machine-readable).

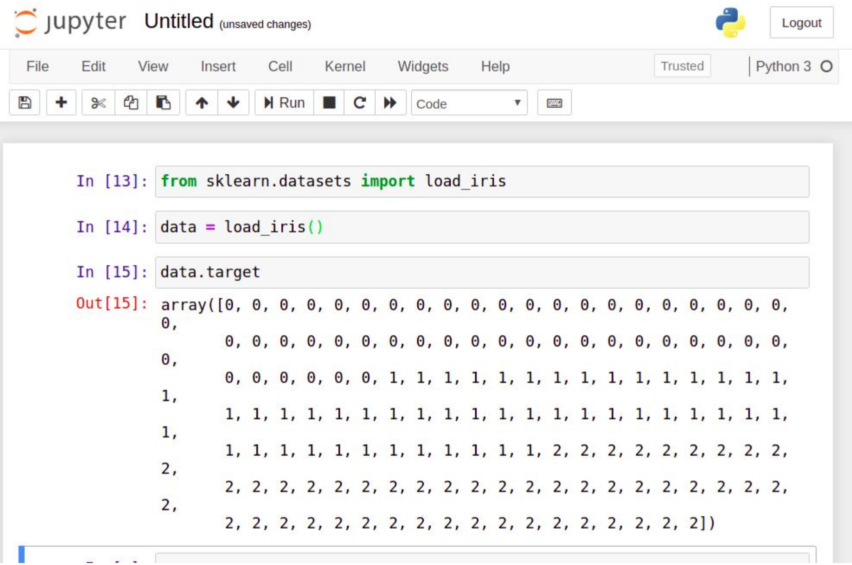

IESB

google colab

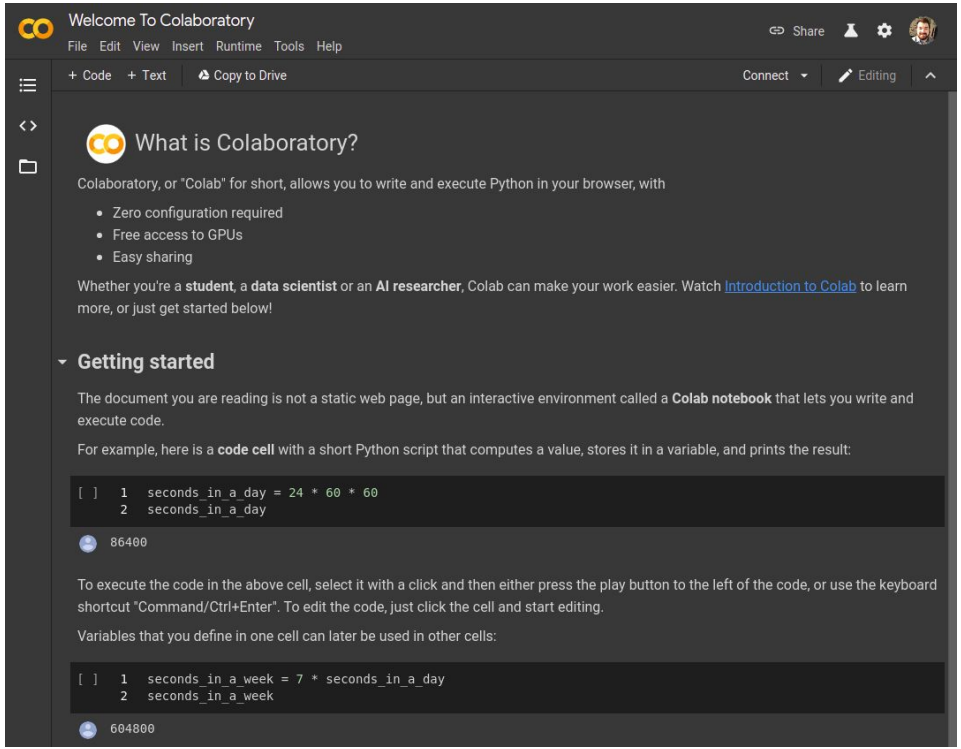

referências importantes

instalação do conda

https://docs.conda.io/projects/conda/en/latest/user-guide/install/index.html#regular-installation

instalação do pip

https://pip.pypa.io/en/stable/installing/

instalação do jupyter notebook

https://jupyter.org/install.html

google colab

https://colab.research.google.com/

Nivelamento (again...)

https://github.com/aulas-iesb/CastoresIndomaveis